

미션 14_SNS 텍스트 감정 분석 및 감정 분류 모델링 보고서


| 팀명: 7팀 · 성명: 김유림 · 작성일: 2026-07-13

1. 분석 개요

SNS 상에서 유저들이 남긴 텍스트 데이터를 활용하여, 각 감정(슬픔·기쁨·사랑·화남·두려움·놀람)에 주로 등장하는 단어를 워드클라우드로 시각화하고, 텍스트를 6가지 감정 중 하나로 분류하는 머신러닝 모델을 구축했다.

데이터 개요

- 학습 데이터(text_emotions_training.csv): 17,948건
- 평가 데이터(text_emotions_test.csv): 2,000건
- 컬럼: `text` (영문 텍스트), `label` (감정 라벨 0~5)
- 라벨: `0-sadness`, `1-joy`, `2-love`, `3-anger`, `4-fear`, `5-surprise`
- 결측치 및 중복 텍스트 없음, 학습/평가 데이터 간 중복 텍스트 없음 (데이터 누수 없음 확인)



joy(6,048)·sadness(5,213)가 다수를 차지하고 love(1,469)·surprise(647)는 상대적으로 적어 클래스 불균형이 존재한다.

2. 데이터 탐색 및 전처리

2.1 텍스트 특징

원본 텍스트는 이미 소문자화되어 있고 구두점이 제거된 상태였으며, 대부분 "i feel ~", "i was feeling ~" 형태의 1인칭 감정 서술 문장으로 구성되어 있었다. 문장 길이는 평균 19 단어, 최소 2단어에서 최대 66단어 사이로 분포했다.

2.2 전처리 파이프라인

1. **정제**: 소문자 변환 및 영문자 이외 문자 제거
2. **불용어 제거**: NLTK의 영어 불용어 사전(stopwords) 적용
3. **품사 태깅(POS tagging)**: NLTK `pos_tag` 로 각 단어의 품사를 추출
4. **표제어 추출(Lemmatization)**: WordNetLemmatizer를 사용하되, 품사 태그를 WordNet 품사로 매핑하여 전달함으로써 동사(feeling → feel, felt → feel)와 명사 표제어 추출 정확도를 높였다. 품사 정보 없이 단순 lemmatize를 적용하면 동사 활용형이 제대로 원형화되지 않는 문제가 있어 이를 교정했다.
5. **짧은 토큰 제거**: 길이 2 이하 토큰 제거

감정	주요 단어 및 해석
surprise	surprised, amazed, weird, strange, shocked 등 → 예상 밖의 상황을 나타내는 단어

감정별 워드클라우드를 대체로 각 감정을 직관적으로 나타내는 형용사(happy, scared, angry 등)가 가장 크게 부각되어, 품사를 명사·형용사로 제한하고 공통 단어를 제외한 전처리 방식이 감정 간 어휘 차이를 효과적으로 드러냄을 확인할 수 있었다.

4. 감정 분류 모델링

4.1 벡터화 및 기본 모델

전처리된 텍스트를 TF-IDF로 벡터화한 뒤, 가장 단순한 형태인 **Logistic Regression**을 1차 베이스라인 모델로 구축했다.

1단계 (베이스라인)

- 전처리: 전체 품사 + 표제어 추출
- 벡터화: TF-IDF(유니그램, max_features=5000)
- 모델: LogisticRegression(기본 설정) → 테스트 **Accuracy 0.856, Macro F1 0.780**

베이스라인 모델의 라벨별 성능을 살펴보면 sadness, joy처럼 데이터가 많은 클래스는 F1 0.89~0.90으로 높았지만, love(F1 0.66), surprise(F1 0.57)처럼 데이터가 적은 클래스에서 성능이 크게 저하되었다. 이는 학습 데이터의 클래스 불균형이 소수 클래스의 재현율(recall)을 낮추는 전형적인 패턴이다.

5. 모델 성능 개선 과정

5.1 클래스 불균형 처리

LogisticRegression의 `class_weight='balanced'` 옵션을 적용해 소수 클래스(love, surprise)에 더 큰 가중치를 부여했다. 그 결과 정확도 0.864, macro F1 0.825로 특히 macro F1이 크게 개선되었다(+0.045). macro F1은 클래스별 성능을 동등하게 반영하는 지표이므로, 이 개선은 불균형 처리가 소수 클래스 인식에 실질적으로 도움이 되었음을 보여준다.


5.2 벡터화 방식 개선

유니그램만 사용할 경우 감정을 구성하는 단어 조합(예: "feel like")의 맥락 정보를 놓칠 수 있다. 이에 바이그램(1~2gram)을 추가하고, `min_df=2` 로 너무 드물게 등장하는 단어를 제거

했으며, `sublinear_tf=True`를 적용해 한 문서 내에서 특정 단어가 지나치게 반복될 때 가중치가 과도하게 커지지 않도록 조정했다. `max_features`는 3000~전체 범위로 실험한 결과 10,000에서 가장 안정적인 성능을 보였다.

5.3 다른 분류 모델과의 비교

동일한 피처로 **RandomForestClassifier**(`n_estimators=300`)를 학습해 비교했다. RandomForest는 정확도 0.863, macro F1 0.804로 Logistic Regression 대비 오히려 성능이 낮고 학습 시간도 약 50배 이상 길었다. TF-IDF로 만들어진 수천 차원의 희소 (sparse) 고차원 벡터에서는 선형 모델인 Logistic Regression이 트리 기반 모델보다 더 적합하다는 결론을 내리고, 최종 모델로는 Logistic Regression 계열을 채택했다. (참고: 동일 피처에 LinearSVC 적용 시 정확도 0.885로 근소하게 더 높았으나 macro F1(0.842)은 거의 동일해, 해석이 쉽고 macro F1이 가장 높은 Logistic Regression을 최종 채택)




6. 최종 모델 평가

최종 모델

- 전처리: 전체 품사 + POS 기반 표제어 추출
- 벡터화: TF-IDF(1~2gram, `min_df=2`, `sublinear_tf=True`, `max_features=10000`)
- 모델: `LogisticRegression(class_weight='balanced', C=1)`
 - 테스트 **Accuracy 0.878, Macro F1 0.843** (베이스라인 대비 Accuracy +2.2%p, Macro F1 +6.3%p)

감정	precision	recall	f1-score	support
sadness	0.93	0.89	0.91	581
joy	0.95	0.87	0.91	695
love	0.67	0.87	0.76	159
anger	0.85	0.89	0.87	275
fear	0.87	0.83	0.85	224
surprise	0.65	0.92	0.76	66



불균형 처리 이후 love와 surprise의 재현율(recall)이 각각 0.87, 0.92까지 크게 상승했다. 혼동 행렬을 보면 love는 joy와, surprise는 fear와 혼동되는 경우가 상대적으로 많았는데, 이는 실제로도 "사랑스러움"과 "기쁨", "놀람"과 "두려움"이 문장 상에서 유사한 어휘로 표현되는 경우가 많기 때문으로 해석된다. 다만 love와 surprise의 precision(0.67, 0.65)은 여전히 상대적으로 낮는데, class_weight로 소수 클래스의 recall을 끌어올리는 대신 precision이 다소 희생되는 전형적인 trade-off가 나타난 것으로 볼 수 있다.

7. 심화 과제: 긍정/부정 이진 분류

가이드라인에 따라 감정 라벨을 다음과 같이 재구성하여 이진 분류 모델을 추가로 구축했다.

- **긍정(1)**: joy, love
- **부정(0)**: sadness, anger, fear
- **제외**: surprise (긍정적 놀라움과 부정적 놀라움이 혼재되어 있어 이진 분류 대상에서 제외)

동일한 전처리·벡터화·모델 설정(TF-IDF 1~2gram + LogisticRegression balanced)을 그대로 적용한 결과는 다음과 같다.

이진 분류 결과

- 테스트 **Accuracy 0.960, F1-score 0.954** (positive 기준)
- 6개 감정 다중 분류(정확도 0.878) 대비 **+8.2%p** 향상

	precision	recall	f1-score	support
negative	0.96	0.97	0.96	1,080
positive	0.96	0.95	0.95	854

클래스 수가 6개에서 2개로 줄어들면서 결정 경계가 단순해졌고, 특히 다중 분류에서 서로 혼동되던 love ↔ joy, surprise ↔ fear 쌍이 각각 긍정/부정 그룹 내부로 통합(surprise는 제외)되면서 오분류 여지가 크게 줄어든 것으로 해석된다. 이는 가이드라인에서 예상한 대로 이진 분류의 정확도가 다중 분류보다 높게 나온다는 것을 확인시켜준다.

8. 결론 및 한계

주요 결론

- POS 태그 기반 표제어 추출과 워드클라우드 전용 불용어 제거를 통해 감정별 어휘 특성을 효과적으로 시각화할 수 있었다.
- 클래스 불균형 처리(`class_weight='balanced'`)가 소수 클래스(love, surprise) 성능 개선에 가장 큰 기여를 했다.
- 바이그램 및 sublinear TF-IDF 적용으로 추가적인 성능 향상을 얻었다.
- 본 데이터(고차원 희소 TF-IDF 벡터)에서는 RandomForest보다 Logistic Regression 계열의 선형 모델이 더 적합했다.
- 감정 라벨을 긍정/부정 이진 구조로 단순화하면 분류 정확도가 크게 향상된다.

한계 및 향후 개선 방향

love와 surprise는 여전히 precision이 낮아 추가 개선 여지가 있다. 향후 Word2Vec·GloVe 등 사전학습 임베딩이나 BERT 기반 문맥 임베딩을 적용하면 단어 순서와 문맥 정보를 반영해 현재 TF-IDF 방식의 한계를 보완할 수 있을 것으로 기대된다. 또한 love·surprise 클래스에 대한 데이터 증강(back-translation, SMOTE 계열 오버샘플링 등)도 소수 클래스 precision 개선에 도움이 될 수 있다.